在线迁移学习

Yuntao Du

September 2020

1 Introduction

在经典的迁移学习场景中，模型都是以离线的方式进行模型的训练: 也就是，在训练开始前，源域和目标域数据都是已经给出的，之后，可以通过一些迁移学习算法进行模型的训练。这也是许多机器学习算法的训练方式。

但在真实的应用场景中，往往并不是这样的: 数据是以在线的方式一点一点源源不断到来的。更一般的，我们会面临这种场景: 源域数据可以被提前收集好，而目标域上的数据要一点一点才能过来，这种场景就是所谓的”在线迁移学习”[1]。“在线迁移学习” 和机器学习中的” 在线学习”[2] 这个场景密切相关，相同点都是训练数据是源源不断到来的，不同点在于 “在线学习” 考虑的是一个域上的数据动态变化，“在线迁移学习” 中是存在源域和目标域两个域的数据，考虑目标域上数据的变化。

针对在线迁移学习相关的研究工作目前还比较少。Steven Hoi 等人于 ICML2010 上发表了在线迁移学习的第一篇工作 [1]。作者首先给出了在线迁移学习的形式化定义。假定存在一个提前收集好的源域 $D_s = \{(x_i^s, y_i^s)\}_{i=1}^{n_s}$ 和在源域上学习出的分类 f_s, 在本方法中，源域和目标域上的分类器都是线性模型，其中源域分类器为 $f_s = sign(v^{\mathrm{T}}x)$。源域分类器可以通过一些在线学习算法进行学习 (PA 算法等) 或传统的机器学习算法 (SVM 等) 进行学习，为了和目标域分类器形式统一，在本文中，作者采用 PA 算法 [3] 进行源域分类器的学习。在目标域上，存在一个以在线方式到来的目标域样本 $D_t = \{(x_i, y_i)|i = 1, 2, ..., T\}$。作者的目标是在目标域上学习一个分类器 f_t，对于时刻 t 上目标域上的样本 x_t, 目标域分类器的输出为 $f(x_t) = sign({w_t}^{\mathrm{T}}x_t)$。

为了从源域中迁移知识到目标领域中，OTL 方法基于集成学习策略来

有效地组合两个分类器。作者引入了两个权重参数 $\alpha_{1,t}$ 和 $\alpha_{2,t}$。在 t 时刻，会收到目标域上的样本 x_t，预测其标签为:

$$\hat{y}_t = sign(\alpha_{1,t}\Pi(v^{\mathrm{T}}x_t) + \alpha_{2,t}\Pi({w_t}^{\mathrm{T}}x_t)) \tag{1}$$

其中 $\Pi(z) = max(0, min(1, \frac{z+1}{2}))$。在模型进行学习之前，作者初始化权重为 $\alpha_{1,1} = \alpha_{2,1} = \frac{1}{2}$。在模型学习的过程中，除了更新目标域分类器参数 w_{t+1}，作者也更新这两个预测函数的权重，更新方法为:

$$\alpha_{1,t+1} = \frac{\alpha_{1,t}s_t(v)}{\alpha_{1,t}s_t(v) + \alpha_{2,t}s_t(w_t)}, \alpha_{2,t+1} = \frac{\alpha_{1,t}s_t(w_t)}{\alpha_{1,t}s_t(v) + \alpha_{2,t}s_t(w_t)} \tag{2}$$

其中 $s_t(u) = exp\{-\eta l^*(\Pi(u^T x_t), \Pi(y_t))\}$，并且 $l^*(z, y) = (z - y)^2$ 是损失函数。对于目标域分类器，作者采用经典的在线学习算法–PA 算法 [3] 进行目标域分类器的更新, 更新方式为: 对于样本 x_t, 其预测损失为 $l_t = [1 - y_t {w_t}^T x_t]_+$, 如果 $l_t > 0$, 则更新模型参数，更新的表达式为:

$$w_{t+1} = w_t + \tau_t y_t x_t, \tau_t = \min\{C, l_t/||x_t||^2\} \tag{3}$$

其中 C 是需要输入的超参数。除了在同构场景下的学习算法，作者还设计在异构场景下的模型学习算法并且进行了算法的理论分析。

QiangYao 等人将这个场景扩展到有多个源域的情形 [4]，同样是以带权分类器集成的方式构建最终的分类器。此外还有一些研究关注于在线迁移学习在一些领域的应用，包括在线特征选择 [5]，物体追踪 [6]，强化迁移学习 [7], 图文检索 [8] 和概念漂移 [9] 等。

之前的方法关注于如何从源域中迁移知识到目标域领域中，而在迁移学习中，影响能否顺利进行迁移的一个很重要的因素是两个域之间的分布差异。在迁移学习中，通常假设源域数据来自分布 $P(x, y)$，目标域数据来自分布 $Q(x, y)$，并且 $P(x, y) \neq Q(x, y)$。根据经典的迁移学习理论 [10]，可以知道，当两个域之间的分布差异较小，模型在目标域上的泛化性能越好。而之前的方法并没有关注域之间的分布差异。针对这个问题，Yuntao 等人提出了一个算法，使得可以在线降低分布差异的同时，进行模型的学习 [11]。作者考虑多个源域的场景，假设有 n 个源域数据 $D_{s_1}, D_{s_2}, ..., D_{s_n}$，其中对于第 i 个源域为 $D_{s_i} = \{(x_j, y_j), j = 1, 2, ..., n_{s_i}\}$。在目标域上，作者假设存在两种数据，第一种是提前可以收集好的无标注数据 $D_t^u = \{x_i, i = 1, 2, ..., n_t^u\}$，另一种是以在线的形式到来的有标签数据 $D_t^l = \{(x_j, y_j), j = 1, 2, ..., T\}$。和文献 [1] 不同，作者在本方法中考虑多分类问题，记类别总数为 K。该算法

的目标是在学习目标域分类器的同时，学习多个映射矩阵 $A_i, i = 1, 2, ..., n$，通过这些映射矩阵将源域和目标域的数据映射到新空间下，从而降低两个域之间的分布差异。

该算法分为离线和在线两阶段。在离线阶段，为了给这些映射矩阵获得一个好的初始化，作者采用 JDA 算法，将其学习出的映射矩阵作为初始化映射矩阵。JDA 算法的学习是在离线阶段进行的，其以源域数据和目标域无标注数据作为输入。在获得初始映射矩阵后，作者将源域数据映射到相应的新空间下，映射之后的数据为 $X_{s_i}^p = A_i X_{s_i}$。基于映射之后的数据，作者采用多类 PA 算法 [3] 在源域数据上学习出 n 个源域分类器 $f_{s_i}, i = 1, 2, ..., n$。

在在线阶段，会以在线的方式收到目标域数据。在 t 时刻，收到的样本为 x_t，作者首先通过在离线阶段学习出的映射矩阵将样本映射到相应新空间下，对于第 i 个映射矩阵，映射之后的目标域数据为 $x_t^{p_i} = A_i x_t$。和文献 [1] 中的方法不同，本方法是在映射后的多个空间上分别进行目标域分类器的学习，因此在目标域上存在 n 个分类器 $f_{t_i}, i = 1, 2, ..., n$。与文献 [1] 的方法类似，作者同样是基于集成的方式来从源域中迁移知识，记第 i 个源域分类器的权重为 u_i，第 i 个目标域分类器的权重为 v_i。对于该样本的预测输出为

$$F_t = \sum_{i=1}^{n} (u_i f_{s_i}^t(x_t^{p_i}) + v_i f_{t_i}^t(x_t^{p_i})), \hat{y_t} = \arg\max_k F_t^k \tag{4}$$

其中 F_t 是一个 K 维的向量，F_t^k 表示在第 k 为上的输出。作者同样通过预测误差进行权重的更新，并且采用多类 PA 算法 [3] 进行目标域模型的更新。

除此之外，作者提出以在线的方式更新映射矩阵，从而可以进一步降低两个域之间的差异。作者考虑两个域之间的边缘分布差异和条件分布差异，并用 MMD 距离 [12] 作为分布差异的度量。基于源域数据和用源域分类器打了伪标签的目标域数据，对于第 i 个源域，其均值记为 $\bar{c}_{s_i}^0$，对于此源域的第 k 个类中心记为 $\bar{c}_{s_i}^k$。同理，记目标域的均值和目标域第 k 个类的类中心为 $\bar{c}_{s_i}^0$ 和 $\bar{c}_t^k$。作者一方面希望第 $t+1$ 时刻的映射矩阵和第 t 时刻的映射矩阵不要偏差太大，另一方面又希望能够降低两个域之间的差异，因此，设置更新映射矩阵的目标为：

$$A_i^{t+1} = \arg\min_A ||A - A_i^t||_F^2 + \mu \sum_{k=1}^{K} ||A_i \bar{c}_{s_i}^k - A_i \bar{c}_t^k||_2^2 \tag{5}$$

对于这个优化问题，可以获得闭式解，映射矩阵的更新方式为

$$A_i^{t+1} = A_i^t(I + \mu \sum_{k=0}^{K}(\overline{c}_{s_i}^k - \overline{c}_t^k)(\overline{c}_{s_i}^k - \overline{c}_t^k)^{\mathrm{T}})^{-1} \tag{6}$$

在模型的训练过程中，随着目标域样本的逐渐增加，可以持续更新样本均值和样本类中心，从而可以更加准确的度量域之间的分布差异。实验效果表明，在考虑数据分布差异后，可以显著提升模型的迁移效果。

参考文献

[1] P. Zhao and S. Hoi. Otl: A framework of online transfer learning. In *ICML*, 2010.

[2] Steven CH Hoi, Doyen Sahoo, Jing Lu, and Peilin Zhao. Online learning: A comprehensive survey. *arXiv preprint arXiv:1802.02871*, 2018.

[3] K. Crammer, O. Dekel, Joseph Keshet, S. Shalev-Shwartz, and Y. Singer. Online passive-aggressive algorithms. In *J. Mach. Learn. Res.*, 2003.

[4] Q. Wu, Hanrui Wu, Xiaoming Zhou, Mingkui Tan, Y. Xu, Yuguang Yan, and T. Hao. Online transfer learning with multiple homogeneous or heterogeneous sources. *IEEE Transactions on Knowledge and Data Engineering*, 29:1494–1507, 2017.

[5] Jialei Wang, P. Zhao, S. Hoi, and Rong Jin. Online feature selection and its applications. *IEEE Transactions on Knowledge and Data Engineering*, 26:698–710, 2014.

[6] Changxin Gao, N. Sang, and Rui Huang. Online transfer boosting for object tracking. *Proceedings of the 21st International Conference on Pattern Recognition (ICPR2012)*, pages 906–909, 2012.

[7] Yusen Zhan and Matthew E Taylor. Online transfer learning in reinforcement learning domains. *arXiv preprint arXiv:1507.00436*, 2015.

[8] Yuguang Yan, Q. Wu, Mingkui Tan, and Huaqing Min. Online heterogeneous transfer learning by weighted offline and online classifiers. In *ECCV Workshops*, 2016.

[9] Helen McKay, N. Griffiths, P. Taylor, T. Damoulas, and Z. Xu. Online transfer learning for concept drifting data streams. In *BigMine@KDD*, 2019.

[10] Shai Ben-David, John Blitzer, K. Crammer, A. Kulesza, Fernando C Pereira, and Jennifer Wortman Vaughan. A theory of learning from different domains. *Machine Learning*, 79:151–175, 2009.

[11] Yuntao Du, Zhiwen Tan, Qian Chen, Y. Zhang, and Chong-Jun Wang. Homogeneous online transfer learning with online distribution discrepancy minimization. In *ECAI*, 2020.

[12] A. Gretton, K. Borgwardt, Malte J. Rasch, B. Schölkopf, and Alex Smola. A kernel method for the two-sample-problem. In *NIPS*, 2006.